

向量检索引擎选型分析报告

主流向量数据库横向对比与选型建议

作者：基础架构选型委员会

日期：2026-07-30

文档编号：SEL-2026-004

目 录

第1章 选型背景与评估维度

第2章 候选引擎对比

第3章 场景化选型建议

第4章 选型结论与风险提示

第1章 选型背景与评估维度

向量检索引擎是知识库与 RAG 系统的核心组件，其性能、稳定性与生态成熟度直接决定上层应用体验。本报告针对企业知识库场景，对主流向量检索引擎进行横向对比，为技术选型提供决策依据。

评估维度涵盖：检索性能(召回率、QPS、延迟)、规模扩展性(单库容量、分布式能力)、数据一致性、过滤检索支持、运维复杂度、社区活跃度与商业支持等七大方面。

评估数据来自标准数据集基准测试与生产环境压力测试，力求客观反映各引擎在真实负载下的表现。

第2章 候选引擎对比

Milvus 作为开源向量数据库的代表，具备完善的分布式架构与丰富的索引类型，在亿级向量场景下表现稳定，但运维复杂度较高，对运维团队有一定要求。其标量过滤能力近年来持续增强，适合复杂过滤场景。

Qdrant 以 Rust 实现著称，单机性能出色，内存占用相对较低，标量过滤与 payload 管理设计优雅，适合中小规模与对延迟敏感的场景，但分布式版本成熟度仍在演进中。

Elasticsearch 与 PostgreSQL(pgvector)作为通用数据库的向量扩展，优势在于与现有技术栈融合度高、事务一致性好，适合向量规模适中且对一致性要求高的场景，但在纯向量检索性能上不及专用引擎。

第3章 场景化选型建议

对于千万级以上向量、需要水平扩展与高并发检索的知识库平台，建议优先选用 Milvus，其分布式能力与生态成熟度最能匹配大规模生产需求。

对于百万级向量、强调低延迟与丰富过滤的业务场景，Qdrant 是性价比突出的选择，运维负担较轻，适合中小团队快速落地。

对于已有 Elasticsearch 或 PostgreSQL 技术栈、向量规模在百万级以内的企业，采用 pgvector 或 ES kNN 可最大化复用现有运维能力，降低引入新组件的复杂度。

第4章 选型结论与风险提示

综合评估，本平台千万级向量与高并发检索的需求下，推荐 Milvus 作为主向量引擎，并预留向 Qdrant 迁移的抽象层，以降低单一供应商锁定风险。

选型风险主要在于引擎版本快速迭代带来的兼容性变化，建议在架构上通过检索抽象层隔离引擎差异，便于后续平滑替换或并存多引擎。

无论选择何种引擎，均应建立常态化基准测试与容量规划机制，提前识别性能拐点，避免业务增长后被动迁移。