

智能问答系统评测方法论

面向 RAG 问答的质量评估框架与指标体系

作者：AI 质量评测中心

日期：2026-07-30

文档编号：EVAL-2026-005

目 录

- 第1章 评测框架设计
- 第2章 自动化指标体系
- 第3章 人工评估流程
- 第4章 评测闭环与持续改进

第1章 评测框架设计

智能问答系统的评测不能仅依赖主观感受，需建立结构化的评测框架。本方法论提出“检索质量—生成质量—端到端体验”三层评测模型，分别对应系统的不同能力维度。

检索质量关注召回率、精确率与排序质量；生成质量关注答案准确性、完整性、相关性与会话连贯性；端到端体验则涵盖响应延迟、稳定性与用户满意度。

评测数据集应覆盖事实型、推理型、多轮对话型与拒答型等多种问题类型，并设置干扰项与边界用例，全面考察系统的鲁棒性。

第2章 自动化指标体系

检索层采用 Recall@k、MRR、NDCG 等经典指标衡量召回与排序质量，配合人工标注的相关性标签进行计算，可纳入持续集成流程实现回归监测。

生成层引入基于大模型的自动评估方法(LLM-as-a-Judge)，从事实一致性、答案相关性、完整性等维度打分，并与少量人工标注交叉校准，兼顾评估效率与可信度。

对于事实一致性，可结合检索证据进行引用核验，检测答案是否能在检索上下文中找到支撑，降低幻觉风险。

第3章 人工评估流程

人工评估采用双盲标注加仲裁机制，每条样本由两名标注员独立评分，分差超过阈值时由资深标注员仲裁，保证标注一致性。标注维度包括准确性、相关性、表达质量与安全性。

评估样本采用分层抽样，按问题类型、业务领域与历史表现加权抽取，确保难例与高频问题得到充分覆盖，避免评测结果被简单用例稀释。

定期组织领域专家进行深度评测，针对专业领域问题给出权威判定，弥补通用标注员在专业知识上的不足。

第4章 评测闭环与持续改进

评测结果需形成可追踪的指标看板，关联到每次系统变更，建立“变更—评测—回归”的闭环，使质量变化可归因、可追溯。

对评测中发现的不良案例建立 badcase 库，按根因分类(召回缺失、排序错误、生成幻觉、上下文溢出等)，指导针对性优化优先级排序。

本方法论建议每两周执行一次全量回归评测，每次重大变更触发增量评测，以数据驱动问答系统质量的持续提升。