

LLM应用可观测性建设方案

大模型应用全链路监控与质量保障体系

作者：可观测性工程组

日期：2026-07-30

文档编号：OBS-2026-008

目 录

第1章 可观测性需求分析

第2章 数据采集与埋点

第3章 监控告警与看板

第4章 质量分析与持续优化

第1章 可观测性需求分析

大模型(LLM)应用相比传统系统具有非确定性输出、长尾延迟与质量难以量化等特征，传统监控手段难以覆盖，亟需建立面向 LLM 应用的专门可观测性体系。

LLM

应用的可观测性需同时关注系统层面(延迟、吞吐、错误率)与业务层面(答案质量、token 消耗、幻觉率)，并将两者关联分析，实现质量问题的快速定位。

本方案面向 RAG 问答、智能客服、内容生成等多种 LLM 应用形态，提供统一的埋点规范、采集架构与分析能力。

第2章 数据采集与埋点

埋点采用 OpenTelemetry 标准，在请求链路中记录每个环节的 span，包括检索召回、重排、prompt 组装、模型调用与后处理，形成完整调用链路，支持端到端耗时分解。

除结构化指标外，对每次模型调用记录输入输出文本、token 数、模型版本与温度等参数，作为质量分析的基础数据，敏感信息在采集前脱敏。

采集数据按采样策略写入时序数据库与对象存储，热数据用于实时监控，冷数据用于离线质量分析与模型迭代评估。

第3章 监控告警与看板

监控看板分为系统健康看板与质量看板两类。系统看板展示 QPS、延迟分位、错误率与资源利用率；质量看板展示答案准确率趋势、幻觉率、拒答率与用户反馈分布。

告警策略结合阈值与异常检测，对延迟突增、错误率攀升、质量指标下滑等异常自动触发，并关联到最近变更，辅助快速归因。

针对成本敏感场景，建立 token 消耗与费用看板，按应用、租户、模型维度拆分，设置预算告警，防止成本失控。

第4章 质量分析与持续优化

基于采集的调用数据，定期开展质量分析，识别高频 badcase 与质量洼地场景，结合用户 thumbs up/down 反馈形成优化输入，驱动 prompt 调整与知识库补全。

建立模型版本对比机制，在新模型上线前基于历史流量回放评估质量与成本变化，避免版本升级带来的隐性质量回退。

本方案通过可观测性将 LLM 应用从“黑盒”转变为“白盒”，为质量保障与持续优化提供数据基石，是大模型应用走向生产化的必备能力。